Bloc 2 : ANALYSER, ORGANISER ET VALORISER LES DONNEES

Analyse de données énergétiques (Production et consommation)

Osman SAID ALI
Ynov Toulouse
2025
M2 data scientist

Table des matières

I. Introduction . . . 3
II. Analyse et modélisation des données . . . 4
II.1. Définition du besoin (C2.1.1) . . . 4
Commanditaire et origine du projet . . . 4
Contexte . . . 4
Méthodologie : entretiens exploratoires . . . 4
Synthèse des besoins exprimés . . . 5
Objectifs smart . . . 5
Utilisateurs finaux et cas d'usage . . . 6
II.2. Compréhension du besoin et définition de l'analyse (C2.1.2) . . . 6
Traduire la problématique en un problème de données . . . 6
Définition des axes d'analyse . . . 8
Définition des métriques . . . 8
II.3. Mise en oeuvre technique du besoin (C2.1.3) . . . 9
Choix des outils de requêtage et de calculs analytiques . . . 10
Connexion à la base de données dans BigQuery . . . 10
Analyse d'exploration de données . . . 12
II.4. Validation des résultats (C2.1.4) . . . 13
Modélisation des relations entre variables . . . 13
III. Visualisation et recommandations techniques . . . 20
III.1. Visualisation de données (C2.2.1) . . . 20
choix des outils de visualisation . . . 20
Sélection des modèles de représentation adaptés . . . 21
III.2. Recommandations techniques (C2.2.2) . . . 23
IV. Accompagnement à l'usage des données . . . 25
IV.1. Identifiaction public visé (C2.3.1) . . . 25
Utilisateurs finaux . . . 25
Analyse des besoins de montée en compétences . . . 26
Détails de la formation et support . . . 26
IV.2. Documentation technique (C2.3.2) . . . 27
V. Synthèse . . . 29
VI. Annexes . . . 30

I. Introduction

De nos jours, les anomalies sur les réseaux électriques sont très fréquentes, tandis que l'analyse des données énergétiques devient plus complexe en raison de nombreux facteurs techniques et contextuels. De plus, l'intégration massive des énergies renouvelables dans ces réseaux introduit de nouveaux facteurs d'instabilité entre la production et la consommation de l'énergie. Ainsi, ces éléments constituent un frein au développement des entreprises du secteur de l'énergie, qui cherchent à améliorer leurs systèmes d'analyse et de prévisions énergétiques.

Par ailleurs, le domaine d'analyse de données connaît une évolution importante, tant en matière d'outils que de techniques. Ces évolutions permettent aux entreprises d'exploiter leurs données pour prendre des décisions pertinentes et assurer une croissance durable.

Dans cette optique, ce projet se concentre sur le cas d'une entreprise fictive energIA, spécialisée dans la distribution et dans la gestion d'énergie. Face à l'évolution accrue de sa consommation énergétique et de productions renouvelables, elle cherche à analyser ses données préalablement collectées pour fiabiliser ses réseaux électriques. La mission principale consiste à construire des tableaux de bord et à produire un rapport d'analyse pertinent et automatisé.

Ce rapport s'articule donc autour de trois grands axes :

- Analyse et modélisation de données.
- Visualisation et recommandations techniques
- Accompagnement à l'usage des données.

Ce cadre vise à proposer une solution intégrée et moderne à l'analyse des données dans le secteur énergétique.

II. Analyse et modélisation des données

II.1. Définition du besoin (C2.1.1)

Commanditaire et origine du projet

Ce projet a été initié à la demande de M. Jean Martin, Directeur Technique de l'entreprise energIA, lors du dernier Comité de Direction. Dans le cadre du plan stratégique 2025–2027, l'entreprise souhaite renforcer la résilience de ses infrastructures énergétiques et développer une culture de pilotage par la donnée. La mission confiée à l'équipe data vise à concevoir des outils analytiques pour fiabiliser les prises de décision et automatiser la supervision du réseau électrique.

Contexte

De récents problèmes de black-out en Espagne et au Portugal(faits réels publiés dans la presse) ont montré la vulnérabilité de systèmes électriques. Ces pannes ont entraîné une perte instantanée de 60 % de la demande électrique du pays (Espagne), soit environ 15 gigawatts de production d'électricité. Après quarante-neuf jours d'investigation, le gouvernement espagnol a publié un rapport montrant une série d'erreurs critiques.

- Surtensions non maîtrisées, avec des fluctuations importantes de tension sur le réseau.
- Mauvaises décisions industrielles.
- Erreurs de programmation et d'analyse.

EnergIA l'entreprise fictive fait face aux mêmes défis : l'intégration des énergies renouvelables, l'instabilité des réseaux, et l'absence d'outils analytiques adaptés limitent sa capacité à prévenir les incidents et à optimiser la gestion de déséquilibres énergétique.

Méthodologie : entretiens exploratoires

Pour comprendre les besoins et cadrer le travail d'analyse, des entretiens ont été menés auprès de sept profils de l'entreprise :

Élément	Détail
Nombre d'entretiens	7
Profils interrogés	1 technicien, 2 opérateurs réseau, 2 ingénieurs, 1 data scientist, 1 directeur de BU
Durée moyenne	45 à 60 minutes
Format	Présentiel et visio
Outils utilisés	Grille d'entretien structurée, enregistrement audio, restitution par synthèse
Axes explorés	Accès aux données, processus de décision, outils actuels, attentes en termes d'analyse et visualisation

Tableau 1 : Synthèse des entretiens utilisateurs

Ces échanges ont permis d'identifier les irritants quotidiens, les lacunes techniques, et les attentes vis-à-vis de l'analytique décisionnelle.

Principaux verbatim :

- “On perd 2 heures par jour à chercher les bonnes données. En urgence, c’est 2 heures de trop.” - Opérateurs
- “On a toutes les données, mais elles ne se parlent pas entre elles.” - Ingénieur systèmes
- “Quand le patron me demande un bilan mensuel, je passe ma semaine à faire du copier-coller sur Excel.” - Technicien réseau
- “Impossible de comparer rapidement les performances de nos différentes sources d’énergie ou de voir les tendances énergétiques et l’impact de la météo sur notre production solaire.”

Synthèse des besoins exprimés

Acteur	Problèmes identifiés	Attentes
Opérateurs	Données dispersées, temps de réaction trop long	Tableaux de bord dynamiques, alertes
Ingénieurs systèmes	Difficultés d’analyse post-incident	Rapports automatisés, modélisation
Data scientists/ technicien	Données non analysées, silotées, valeurs aberrantes	Détection d’anomalies, données propres.
Responsables métiers	Indicateurs peu lisibles, décisions incertaines	KPIs synthétiques, recommandations

Tableau 2 : Problèmes et attentes des parties prenantes

Problématique principale:

- L’incapacité actuelle d’energIA à analyser de manière croisée et en quasi temps réel ses données de productions et de consommation l’expose à des risques critiques (similaires aux black-outs récents en Europe et aux pertes financières importantes) et freine sa capacité à optimiser le rendement de ses actifs renouvelables. Comment pouvons-nous transformer nos données silotées en un levier de décision stratégique pour garantir la stabilité du réseau, réduire les coûts liés aux déséquilibres et reduire les anomalies sur le réseau ?

Objectifs smart

Objectif métier	Cible quantifiée
Réduire le temps d’analyse de données	entre (3 jour à 5 jours) à 5–10 minutes
Réduire le taux d’erreurs dans la prise de décision	De 20 % à moins de 5 %
Développer des outils de tests d’hypothèse	Corrélation et causalité entre les données
Automatiser les rapports d’analyse	90 % des rapports générés sans intervention
Favoriser l’adoption des outils (satisfaction utilisateur)	+80 % d’utilisation par les équipes techniques

Tableau 3 : Objectifs métiers et cibles associées

Utilisateurs finaux et cas d'usage

Profil utilisateur	Usage attendu
Opérateurs marché de l'électricté	Suivi de productions, consommation et le déficit
Techniciens /Ingénieurs systèmes	tests et analyse, planification de maintenance
Data scientists / analystes	modélisation, détection d'anomalie, prévision
Responsables métiers	Consultation KPI, suivi de performance, prise de décision stratégique

Tableau 4 : Usages attendus selon les profils utilisateurs

II.2. Compréhension du besoin et définition de l'analyse (C2.1.2)

Comprendre le besoin métier et le traduire en problématique de données constituent le point clé d'un projet d'analyse. Il s'agit ici de convertir une problématique exprimée en langage métier en un problème d'analyse numérique, exploitable via les données disponibles. Cette étape permet de garantir que l'analyse produite répondra effectivement aux attentes opérationnelles et stratégiques des utilisateurs finaux.

Traduire la problématique en un problème de données

Il est essentiel de rappeler que produire des tableaux de bord ou générer des rapports d'analyse n'a de valeur que s'ils répondent à une problématique concrète et bien définie par les parties prenantes. Dans le cas de l'entreprise fictive energIA, la problématique métier peut être formulée de la manière suivante :

Problématique métier :

- Comment analyser et visualiser automatiquement les données de productions et consommation afin d'optimiser l'équilibrage du réseau, identifier les tendances, anticiper les anomalies et piloter efficacement les infrastructures d'energIA ?

Cette problématique peut donc être traduite en un problème d'analyse de données, structuré autour des objectifs suivants :

- Surveiller à intervalle régulier les indicateurs clés de performances.
- Réaliser des analyses statistiques pour identifier de tendances et de saisonnalités et aussi facilité l'interprétation de résultats avec des variables exogènes telles que la température.
- Mettre en place des visualisations claires et interactives à travers un tableau de bord pour faciliter l'accessibilité rapide aux analyses.

Ces objectifs peuvent évoluer à mesure de l'avancée du projet. Il est donc indispensable de les partager et de les valider régulièrement avec les équipes métiers afin de s'assurer de leur pertinence continue.

Identification des données nécessaires

L'identification des données nécessaires consiste dans le cas présent à sélectionner les données disponibles et pertinentes pour répondre à la problématique définie. Dans ce projet, il s'agit de données temporelles liées :

- Aux différentes productions énergétiques (production en MW).
- A la consommation énergétique (consommation totale en MW).
- Aux données météorologiques pouvant impacter les productions et la consommation (température).

Type de donnée	Granularité temporelle	Source de donnée
Productions	1 heure	API interne
Consommation d'électricité	15 minutes	API interne
Météorologique	1 heure	API (open Weather Map)

Tableau 5 : Les données disponibles

Toutes ces données sont stockées dans un entrepôt de données PostgreSQL et Bigquery. Elles sont donc disponibles en interne via des requêtes SQL. Un pipeline ETL, orchestré par Airflow, permet d'assurer la mise à jour de ces données à des intervalles décrits dans le tableau 5. Ces données sont donc pertinentes pour répondre à la problématique définie. En ce qui concerne les données météorologiques, elles peuvent être utilisées pour faciliter l'interprétation de certaines variations jugées anormales, ainsi que pour analyser leurs corrélations avec les autres variables.

Données de productions

- Données photovoltaïque avec un historique de 66 550 points.
- Données éolienne avec un historique de 66 550 points.
- Données biomasses avec un historique de 66 550 points.
- Données nucléaire avec un historique de 66 551 points.

Données de consommation

- Données consommation totale avec un historique de 266 204 points (granularité 15 min).

Données météorologiques

- Données de température avec un historique de 66 551 points.

Qualite de données

Un travail de qualité des données sera nécessaire pour garantir la fiabilité des analyses :

- Compléter les valeurs manquantes par la moyenne, la médiane, l'interpolation linéaire ou en utilisant des algorithmes de Machine Learning (par exemple : KNNImputer), et signaler toute alerte de données manquantes..
- Effectuer un alignement temporel (par exemple une moyenne horaire) afin de fiabiliser le calcul du déficit énergétique, qui compare directement la production totale et la consommation à un instant T.
- Mettre en place une détection d'anomalies (Isolation Forest, Z-score ou IQR)

Définition des axes d'analyse

Les axes d'analyse sont les dimensions ou critères à partir desquels nous structurons l'étude des données. ces derniers permettent de regrouper, filtrer, croiser ou comparer les informations afin d'extraire des éléments pertinents et d'interpréter les phénomènes observés.

Ces axes correspondent généralement à des variables qualitatives, telles que la date, la localisation géographique ou le type de source, qui offrent différents points de vue pour observer les variations d'une ou plusieurs mesures quantitatives, comme la consommation ou la production. Après avoir défini le rôle et la nature des axes d'analyse, nous pouvons maintenant préciser ceux utilisés dans notre projet. Sur la base de la problématique et des données identifiées, l'analyse s'organise autour des dimensions suivantes :

Axe	Description
Temporel	Patterns journaliers, saisonnalité, évolution tendancielle
source énergétique	Performance par type (biomasse, solaire, éolien, nucléaire)
Equilibrage énergétique	Analyse production vs consommation, taux de couverture
performance	KPIs opérationnels, efficacité du réseau

Tableau 6 : Les axes d'analyse du projet

Ces axes guident la construction des visualisations et des modèles analytiques, et permettent d'évaluer la performance énergétique et la robustesse du réseau électrique.

Définition des métriques

Les métriques sont des indicateurs clés de performances qui permettent de mesurer, surveiller et évaluer un système à travers les données. Elles sont la base de l'analyse quantitative, car elles traduisent les comportements, les performances ou les anomalies en valeurs mesurables.

Contrairement aux axes d'analyse, qui sont des dimensions de regroupement (ex : temps, type d'énergie), les métriques sont des résultats de calculs ou d'agrégations appliquées saux données. Elles permettent de prendre des décisions fondées sur des preuves mesurables.

Dans de ce projet, les métriques ont été définies en lien direct avec la problématique métier : améliorer la réactivité de l'entreprise face aux anomalies et les déficits énergétiques. Elles sont réparties selon trois objectifs :

Métrique	Description	Unité
Production totale	Puissance totale produite	Watt
Consommation totale	Puissance totale consommée	Watt
Différentes sources de production	Production de sources (Biomass, solaire, éolienne etc…)	Watt
Taux de couverture	Ratio production / consommation	%
Déficit énergétique	La différence entre production et consommation	Watt
Nombre de déficit	Nombre de déficit énergétique par jour ou mois	—-

Tableau 7 : Surveillance de la performance énergétique

Métrique	Description	Méthodes
Tendances	Détecter les insights	analyse statistique
Répartition de produtions	Pourcentage de production d'une source par rapport à la production totale	calcul analytique
Nombre de variations détectées	Nombre de variations anormales	Méthode statistiques IQR, z-score
déficit énergétique	Compter le nombre de jour de déséquilibres	Différence entre prod et conso

Tableau 8 : Tendances et analyse

Métrique	Description	Objectif métier
Taux d'explicabilité des résultats	% de corrélation à un facteur météo	Améliorer l'analyse causale
Taux de mise à jour des données	Respect des fréquences de données (tab 5)	Automatisation continue
Disponibilité des dashboards	Accessibilité du système de visualisation	99 % de disponibilité
Taux de satisfaction utilisateurs	Retour d'expérience utilisateur	adoption de la culture de donnée

Tableau 9 : Fiabilité et interprétabilité

II.3. Mise en oeuvre technique du besoin (C2.1.3)

Cette section présente la mise en oeuvre technique de l'analyse, à partir des données collectées. L'objectif est de produire des résultats pour aider à prendre des décisions fiables, grâce à des requêtes et calculs analytiques réalisés avec des outils adaptés. Pour cela, nous avons défini un plan très simple qui s'articule autour de trois axes : le choix des outils pour l'extraction, l'analyse(exploration et exploitation) et la visualisation.

Choix des outils de requêtage et de calculs analytiques

Avant toute exploration et exploitation de données collectées, il est important de choisir les technologies de requêtage de données et de calcul. Il existe plusieurs outils pour le requêtage, l'analyse et la visualtion. Dans notre cas, les données étant déjà hébergées sur GCP (Google Cloud Platform) dans PostgreSQL et BigQuery, l'outil de requêtage retenu pour l'extraction et la création de vues est SQL. Pour les analyses, nous utilisons des notebooks Python dans BigQuery, ce qui nous permet d'effectuer l'exploration, l'analyse statistique avancée, la détection d'anomalies et la mise en place de tests d'hypothèses.

Connexion à la base de données dans BigQuery

Les données issues des API internes et externes (météorologiques) ont été intégrées dans PostgreSQL et BigQuery via un pipeline ETL orchestré avec Airflow. Une première étape a consisté à harmoniser la granularité temporelle (conversion à une granularité horaire) et à synchroniser les horodatages entre les tables.

Création d'un espace de travail dans BigQuery :

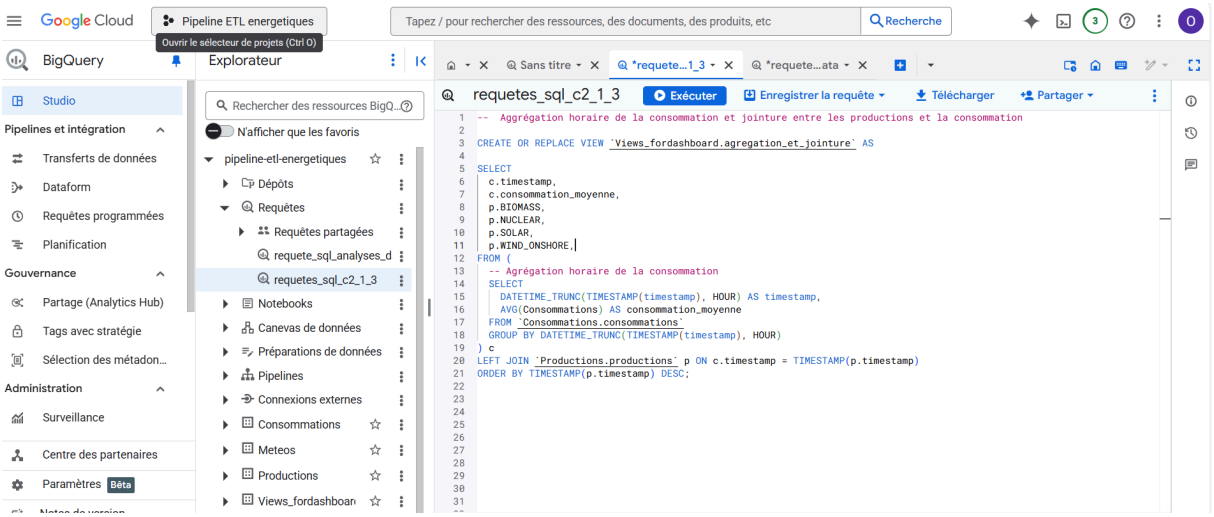

Figure 1 : Environnement de travail sous BigQuery

Préparation et Calcul des Métriques avec SQL : une Approche en Deux Vues

Pour garantir la modularité et la clarté de notre travail, nous avons adopté une stratégie en deux vues SQL distinctes.

1. Vue de Base : Agrégation et Jointure

Une première Vue, nommée `agregation_et_jointure`, a été créée pour servir de base technique propre et fiable. Son objectif est d'harmoniser la granularité temporelle des différentes sources (conversion à une granularité horaire pour la consommation) et de les joindre en une seule table cohérente.

Exemple de création d'une vue BigQuery pour l'agrégation horaire et la jointure de plusieurs sources :

```sql
--  Aggrégation horaire de la consommation et jointure entre les productions et la consommation

CREATE OR REPLACE VIEW `Views_fordashboard.agregation_et_jointure` AS

SELECT
  c.timestamp, c.consommation_moyenne, p.BIOMASS, p.NUCLEAR,
  p.SOLAR, p.WIND_ONSHORE,
FROM (
  -- Agrégation horaire de la consommation
  SELECT
    DATETIME_TRUNC(TIMESTAMP(timestamp), HOUR) AS timestamp,
    AVG(Consommations) AS consommation_moyenne
  FROM `Consommations.consommations`
  GROUP BY DATETIME_TRUNC(TIMESTAMP(timestamp), HOUR)
) c
LEFT JOIN `Productions.productions` p ON c.timestamp = TIMESTAMP(p.timestamp)
ORDER BY TIMESTAMP(p.timestamp) DESC;
```

2. Vue Analytique : Calcul des Métriques Métier

Sur la base de cette Vue consolidée, une seconde Vue, nommée `taux_de_couverture_energetique` , a été développée pour calculer les métriques métiers spécifiques définies précédemment (C2.1.2), telles que la production totale, le taux de couverture et le déficit énergétique.

Exemple de requête SQL pour la création de la vue analytique :

```sql
  -- Calcul des indicateurs de performance énergétique
CREATE OR REPLACE VIEW `Views_fordashboard.taux_de_couverture_energetique` AS
SELECT
    v.timestamp,
    v.consommation_moyenne,
    v.BIOMASS,
    v.NUCLEAR,
    v.SOLAR,
    v.WIND_ONSHORE,
    -- Calcul de la production totale
    (COALESCE(v.BIOMASS, 0) + COALESCE(v.NUCLEAR, 0) + COALESCE(v.SOLAR, 0) + COALESCE(v.WIND_ONSHORE, 0)) AS production_totale,
    -- Calcul du Taux de couverture (%)
    SAFE_DIVIDE((COALESCE(v.BIOMASS, 0) + COALESCE(v.NUCLEAR, 0) + COALESCE(v.SOLAR, 0) + COALESCE(v.WIND_ONSHORE, 0)), v.consommation_moyenne) * 100 AS taux_couverture_pourcent,
    -- Calcul du Déficit énergétique (W)
    (COALESCE(v.BIOMASS, 0) + COALESCE(v.NUCLEAR, 0) + COALESCE(v.SOLAR, 0) + COALESCE(v.WIND_ONSHORE, 0)) - v.consommation_moyenne AS balancing_energetique
FROM `Views_fordashboard.agregation_et_jointure` v;
```

Cette vue enrichie, `taux_de_couverture_energetique` , servira de source de données unique pour l'analyse exploratoire dans Python et pour les futurs tableaux de bord.

Analyse d'exploration de données

Une fois les vues créées, les données ont été chargées dans un notebook Python sur BigQuery pour l'analyse. Cette étape a permis de réaliser des calculs plus complexes et de préparer les métriques définies précédemment.

- Traitement de valeurs manquantes et de doublons.
- Statistiques descriptives (moyenne, écart-type, médiane) par type d'énergie.
- Visualisation exploratoire (boxplots, courbes temporelles) pour repérer les saisonnalités et les valeurs aberrantes.

Les données de la vue `taux_de_couverture_energetique` ont été importées dans un DataFrame pandas. Un premier traitement a permis de gérer les quelques valeurs manquantes identifiées (par exemple, sur `BIOMASS` , `SOLAR` et `WIND_ONSHORE`) en utilisant une méthode d'interpolation linéaire simple pour préserver la structure temporelle de données sans introduire la complexité d'un modèle de Machine Learning.

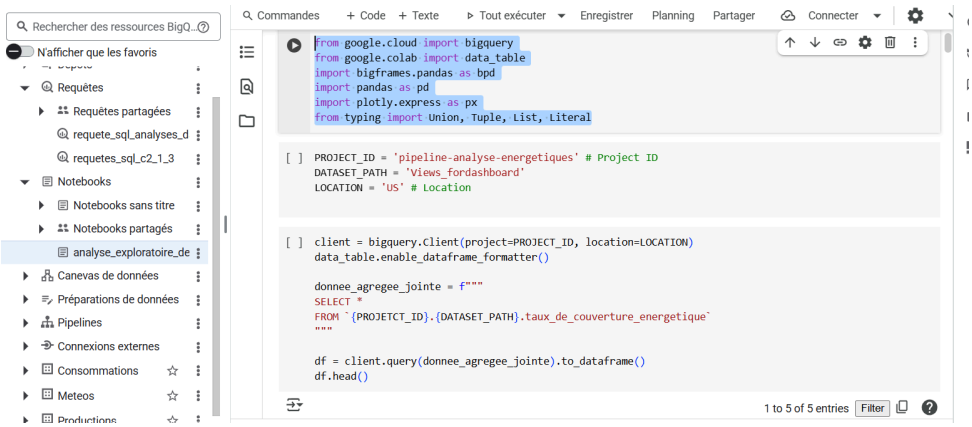

Figure 2 : Espace de travail pour l'analyse exploratoire de données

Pour répondre aux besoins d'analyse, quelques métriques clés ont été calculées directement dans Python, enrichissant ainsi notre jeu de données. Pour ce projet, nous n'avons que des données quantitatives. Voici les statistiques descriptives de ces données :

index	BIOMASS	NUCLEAR	SOLAR	WIND_ONSHORE	consommation_totale	product
count	66197.0	66198.0	66197.0	66197.0	66198.0	
mean	362.2198740124175	39302.83585606816	1934.2940314515763	4197.834448691028	51119.299510559234	45797.0
std	80.90343654805632	8042.806306839646	2916.7039845147287	3165.6502497619217	11189.823783156244	8784.629
min	21.0	0.0	0.0	0.0	28657.0	
25%	323.0	34679.0	0.0	1830.0	42777.25	
50%	343.0	39854.0	259.0	3167.0	49299.5	
75%	367.0	44065.0	3169.0	5760.0	58372.0	
max	1773.0	109356.0	30734.0	21538.0	94912.0	

Show 25 per page

Figure 3 : Statistiques de base

Cela permet de contextualiser les valeurs et d'obtenir un aperçu de la distribution des données.

Détection des anomalies (script Python)

Nous avons utilisé une méthode simple qui détecte les valeurs aberrantes d'une variable à partir de l' `IQR` .

Cette méthode repose sur la différence entre le troisième quartile Q_3 et le premier quartile Q_1 :

$$\text{IQR} = Q_3 - Q_1$$

Àinsi calcul un intervalle interquartile, nous définissons des bornes de détection, c'est-à-dire un borne inférieur et un borne suppérieur déterminé via un coéfficient de 1.5 ou 3 pour ne détecter que les valeurs extremes.

Pour nos données :

- Consommation totale : `395` anomalies détectées sur 66 551 enregistrements, soit environ 0,6 %.
- Production totale : `711` anomalies détectées sur 66 551 enregistrements, soit environ 1,07 %.

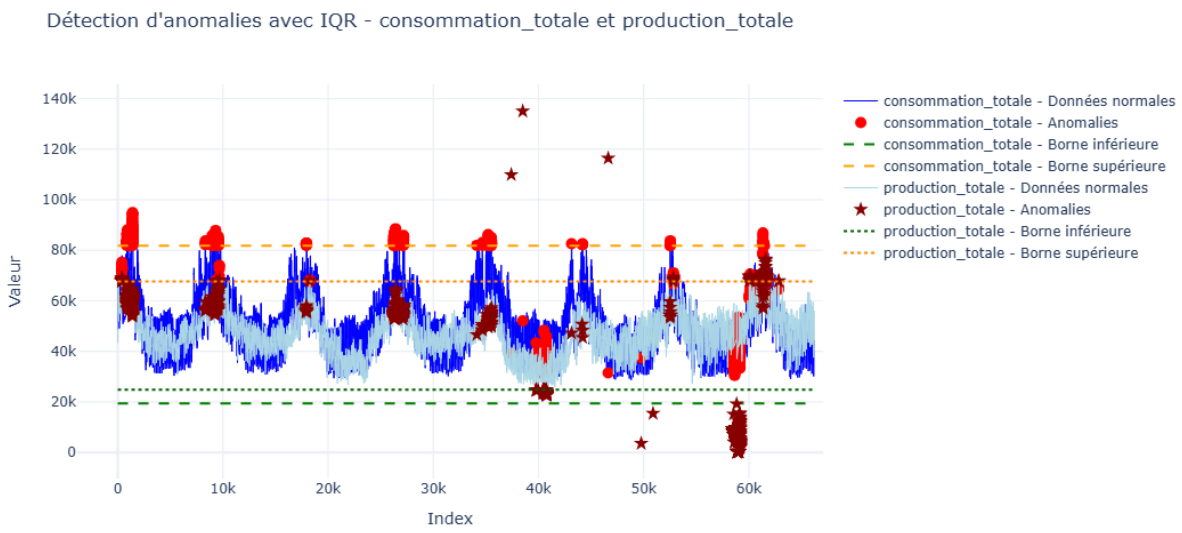

Figure 4 : Détection d'anomalies sur la production totale et la consommation

Ces résultats fournissent un premier indicateur de la qualité et de la variabilité des données, et serviront de base à des analyses plus approfondies. Une première interprétation est que les variations anormales sont souvent en hiver à l'exception de l'année 2022 et 2025 où nous observons ces variations en septembre et octobre.

II.4. Validation des résultats (C2.1.4)

La validation des résultats vise à s'assurer que les analyses réalisées sont fiables, pertinentes et exploitables par les métiers.Cette étape repose sur 4 volets :

- Identifier la corrélation entre les variables et leur significativité.
- Vérifier les tests d'hypothèse statistiques.
- Validation des modèles de détection d'anomalies.
- Validation des hypothèses métier energIA.

Modélisation des relations entre variables

Analyse de corrélation entre les variables

Une matrice de corrélation a été établie entre l'ensemble des variables énergétiques (production totale, consommation, production solaire, éolienne, biomasse, nucléaire) et la variable température. Cette corrélation entre ces variables quantitatives nous indiquera le type, le sens et l'intensité de ces relations, c'est-à-dire voir si la variation de consommation est associée à celle de la température.

Ainsi, Il existe plusieurs types de corrélation comme :

- Corrélation de Pearson mesure la force et la direction d'une relation linéaire.
- Corrélation de Spearman mesure la relation monotone, basée sur les rangs des valeurs.
- Corrélation de Kendall mesure l'association entre les rangs, robuste aux valeurs aberrantes.

D'autres approches existent, mais dans notre cas, les données étant de nature temporelle et quantitatives continues, nous avons appliqué la corrélation de Pearson. Les résultats sont présentés à la figure 5.

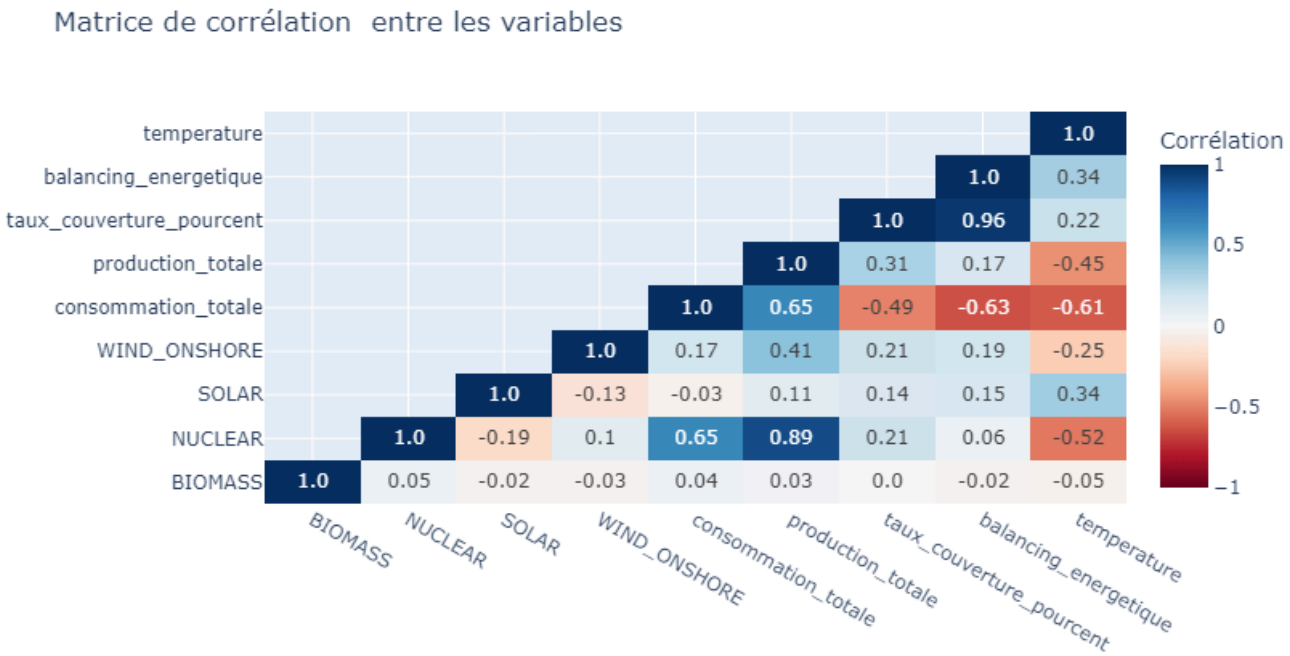

Figure 5 : Matrice de corrélation

D'après ce résultat, nous constatons que certaines variables sont fortement corrélées comme la production et la consommation, pour confirmer la significativité statistique de ces relations, il est important de calculer le p-value, dans le cas présent nous avons 66 551 échantillons donc toutes les variables sont statistiquement signicatives avec un p-value proche de 0.

- Une forte corrélation positive entre la production totale et la consommation qui confirme que la production suit étroitement la demande.
- Une forte corrélation positive entre la production totale et le nucléaire indiquant que la production nucléaire contribue plus à la production totale.
- Une très forte corrélation entre le taux de couverture et le déficit énergétique.

- Une corrélation négative montrant que plus la température augmente, plus la consommation baisse, effet saisonnier attendu.
- Une relation modérée positive entre la production photovoltaique et la température, montrant l'effet saisonnier de la production photovoltaique.

En revanche, les corrélations impliquant la biomasse avec la plupart des autres variables sont moins importantes mais significatives, ce qui suggère que sa production ne suit pas directement les variations de température ou de consommation etc.

Ces résultats justifient l'utilisation de la corrélation de Pearson, adaptée aux variables continues et aux relations linéaires, et confirment la présence de relations structurelles fortes dans le mix énergétique (solaire, éolienne), en particulier autour du nucléaire et de la consommation totale.

Modélisation des relations causales

L'analyse de corrélation a montré des liens statistiques entre nos variables, mais elle ne prouve pas la présence d'un lien de causalité entre elles et que ceci est peut-être du au hasard. Par exemple, une forte corrélation quelle soit positive ou négative entre la température et la consommation energétique ne signifie pas que la température cause directement la consommation, les deux peuvent être influencées par un autre facteur commun, comme la saison. Pour cela, les modèles causaux permettent de déterminer de cause à effet et le sens de l'influence entre deux variables.

Comme nous avons de données chronologiques, nous utilisons le test de causalité de Granger. Ce test de Grange permet de savoir si une variable temporelle `X` aide à prédire une autre variable `Y`, en se basant sur les valeurs passées.

Nous avons appliqué ce test aux variables les plus importantes identifiées par la corrélation, avec comme hypothèses :

- H0 : les valeurs passées de `X` n'aident pas à prédire `Y`.
- H1 : les valeurs passées de `X` améliorent la prédiction de `Y`.

Exemple de code de tests significativité simple de Granger.

```
from statsmodels.tsa.stattools import grangercausalitytestsdef
test_causalite(df, var1, var2, lags):

    test_1 = grangercausalitytests(df[[var1, var2]],
                                   maxlag=lags, verbose=True)
    test_2 = grangercausalitytests(df[[var2, var1]],
                                   maxlag=lags, verbose=True)
    p_value_1 = test_1[lags][0]['ssr_ftest'][1]
    p_value_2 = test_2[lags][0]['ssr_ftest'][1]

    if p_value_1 < 0.05:
        print(f"La variable {var1} cause la variable {var2}")
    else:
        print(f"La variable {var1} ne cause pas la variable {var2}")

    if p_value_2 < 0.05:
```

```
        print(f"La variable {var2} cause la variable {var1}")
    else:
        print(f"La variable {var2} ne cause pas la variable {var1}")
```

Relation	Causalité	Sens	p-value	R^2
Température et Production totale	Oui / Oui	Les 2 sens	0.0/0.0	0.435
Température et Consommation totale	Oui / Non	un sens température cause consommation totale	0.0/0.14	0.703
Température et Solaire	Oui / Oui	Les 2 sens	0.0/0.0	0.588
Température et Éolien	Oui / Oui	Les deux sens	0.0/0.0	0.163
Température et Nucléaire	Oui / Oui	Les deux sens	0.0/0.0	0.391

Tableau 10 : Modélisation de causalité

Interprétation des résultats

1. Température et consommation totale
   - La causalité détectée par le test de Granger montre que la température influence la consommation énergétique, notamment via les usages liés au chauffage et à la climatisation(on parle de thermosensibilité). Ce résultat est corroboré par le modèle de régression multiple intégrant température, heure, jour et saison, qui explique une part importante de la variance de la consommation, avec un coefficient de détermination (R^2) élevé.
2. Autres relations (production totale, solaire, éolien, nucléaire)
   - Le test de causalité de Granger détecte une influence bidirectionnelle avec la température, les coefficients de détermination R^2 varient entre 0.16 et 0.59 selon les sources. Ce qui veut dire que la température n'explique qu'une partie de la variabilité de ces productions. Ces causalités à double sens dues à des facteurs communs, comme la météo et les saisons, plutôt qu'à une causalité directe entre la température et la production énergétique.
3. Qualité des résultats
   - L'analyse des résidus de la régression confirme que les hypothèses fondamentales du modèle (homoscédasticité, normalité et indépendance des erreurs) sont globalement respectées, garantissant la validité des conclusions. Certaines analyses résiduelles sont dans l'annexe.

Tests d'hypothèses statistiques

Les hypothèses en statistiques permettent d'accepter ou de rejeter une affirmation sur un phénomène observé, en se basant sur les données disponibles. nous formulons trois hypothèses principales :

- H1 : Le déficit énergétique n'est pas saisonier.

- H2 : Toutes nos sources énergétiques présentent une moyenne et une variance constantes dans le temps, autrement dit, elles sont stationnaires.
- H3 : Les anomalies détectées sur le réseau électrique ne présentent pas de variations saisonnières.

Ces hypothèses seront testées à l'aide de méthodes statistiques adaptées afin de valider ou d'invalider ces postulats et mieux comprendre la dynamique énergétique observée.

Hypothèse 1

Pour accepter ou réfuter la première hypothèse, nous utiliserons la méthode de décomposition des séries temporelles, adaptée à la structure temporelle de nos données. Cette approche permet de décomposer une série en plusieurs composantes distinctes :

- Tendance : évolution générale à long terme de la série,
- Saisonnalité : variations périodiques et récurrentes liées aux saisons,
- Résidus : composante aléatoire, non expliquée par la tendance ni la saisonnalité.

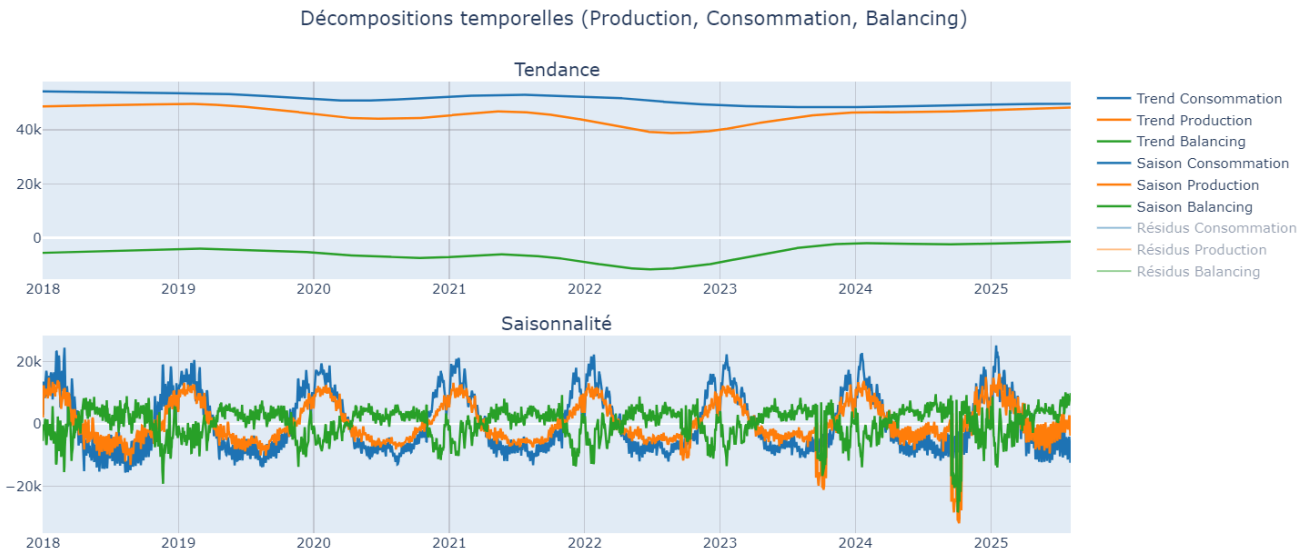

Figure 6 : Décomposition des données de production et consommation

D'après la figure de décomposition, la production totale et la consommation présentent toutes deux une saisonnalité marquée : la consommation est plus élevée en hiver, tout comme la production, et cela se reflète également dans le déficit énergétique.

- H1 (absence de variation saisonnière) est donc rejetée : le déficit énergétique suit un cycle saisonnier fort, régulier et prévisible, avec un déficit hivernal récurrent.

Hypothèse 2

L'hypothèse H2 suppose que les séries temporelles représentant la production totale et la consommation d'énergie sont stationnaires, c'est-à-dire que leurs propriétés statistiques (moyenne, variance, autocorrélation) restent constantes dans le temps.

Pour valider ou rejeter cette hypothèse, des tests de stationnarité sont nécessaires. Pour cela, nous utiliserons le test de Dickey-Fuller augmenté (ADF). Ce test permet de savoir si une série

temporelle est stationnaire c'est-à-dire si ses propriétés statistiques (moyenne, variance, auto-corrélation) varient ou pas dans le temps.

Exemple de code python

```python
from statsmodels.tsa.stattools import adfuller
def verify_stationary(data):
        result = adfuller(data)
        print(f'Value of Test statistic : {result[0]}')
        print(f'p-value : {result[1]}')
        print('La série temporelle est stationnaire' if result[1] < 0.05 else "La série n'est pas stationnaire")
```

Série	Statistique du test	p-value	Stationnaire ?
Production totale	−8.4444	1.73e-13	Oui
Consommation totale	−8.1244	1.13e-12	Oui
Bilan énergétique	−11.7930	9.72e-22	Oui
Température	−8.5921	7.24e-14	Oui
SOLAR	−8.9551	8.52e-15	Oui
WIND_ONSHORE	−18.1413	2.49e-30	Oui
NUCLEAR	−7.1487	3.18e-10	Oui

Tableau 11 : Test de stationnarité

Les tests de stationnarité montrent que toutes les séries (production totale, consommation totale, déficit énergétique, température et sources d'énergie) sont stationnaires. Les statistiques et p-values confirment que leurs propriétés statistiques restent stables dans le temps. Par conséquent, l'hypothèse H2 est acceptée : les séries peuvent être modélisées sans transformation préalable pour la stationnarité (comme la différenciation), bien que la composante saisonnière doit être impérativement prise en compte dans les modèles prédictifs..

Hypothèse 3

L'hypothèse H3 suppose que les anomalies détectées dans les données sont indépendantes des saisons. En d'autres termes, la survenue des anomalies ne dépendrait pas de la période saisonnière.

Pour tester cette hypothèse, un test du Chi-2 d'indépendance est appliqué sur un tableau regroupant les anomalies par saison.

- Si la statistique de test est faible et la p-value élevée (supérieure au seuil de 0,05), H3 est acceptée, indiquant qu'il n'y a pas d'association significative entre anomalies et saisons.
- Si la statistique est élevée et la p-value faible (inférieure à 0,05), H3 est rejetée, ce qui montre que les anomalies dépendent des saisons.

	Anomalie production détectée	Anomalie consommation détectée
Automne	594	1
Hiver	81	377
Printemps	4	17
Été	32	0
Statistiques	**Chi-2 : 1512.26**	**Chi-2 : 1069.31**
p-value	**0.0000**	**1.65e-231**

Tableau 12 : Test de du chi2

Le tableau montre que les anomalies de production sont surtout nombreuses en automne, tandis que les anomalies de consommation apparaissent principalement en hiver.

Les tests statistiques confirment que la saison a un effet significatif sur la fréquence des anomalies, avec une variation claire selon les saisons. Par conséquent, l'hypothèse 3 est rejetée : les anomalies ne sont pas réparties au hasard dans l'année.

Après avoir testé nos hypothèses, nous constatons que le déficit énergétique présente une forte saisonnalité, avec un pic moyen très élevé en hiver (H1). Par ailleurs, l'analyse de stationnarité (H2) confirme la stabilité des sources et de la consommation totale dans le temps, ce qui facilite la modélisation et la prévision. Enfin, les anomalies sont fréquentes et varient selon les saisons, avec une concentration notable en hiver et en automne (H3).

Ces résultats soulignent l'importance d'intégrer la dimension saisonnière dans la planification énergétique. Pour optimiser la gestion du système, il est essentiel d'adapter les stratégies de maintenance, de production et de consommation en tenant compte des variations saisonnières et des périodes à risque, afin de réduire le déficit et limiter les anomalies. Une surveillance renforcée des productions et de la consommation en automne et en hiver est donc indispensable pour mieux maîtriser ces risques.

III. Visualisation et recommandations techniques

Cette section représente le coeur de notre projet. Elle est aussi une étape clé d'un projet d'analyse c'est-à-dire transformer des analyses complexes en informations visuelles, interactives, claires et exploitables. L'objectif est de mettre en valeur les données préparées pour permettre aux parties prenantes d'energIA de comprendre, d'analyser d'identifier d'identifier les tendances, anomalies énergétiques et de prendre des décisions pertinentes. Pour ce faire, nous aborderons le choix de l'outil de visualisation et la sélection des représentations graphiques les plus pertinentes.

III.1. Visualisation de données (C2.2.1)

La visualisation de données, ou dataviz, est une manière très simple de représenter graphiquement des données pour en extraire du sens. Dans le cas d'energIA, où les volumes de données temporelles sont importants et les utilisateurs finaux variés (techniciens, opérateurs, ingénieurs, responsables). Ainsi, le choix d'un outil adapté est fondamental pour garantir l'adoption et l'efficacité de la solution analytique. Pour cela nous allons dresser un tableau comparatif des différents outils existants.

choix des outils de visualisation

Il existe une panopile d'outils pour faire de la visualisation, chacun présentant des avantages et inconvénients selon le contexte d'usage. Pour energIA, nous avons évalué les principaux alternatifs selon cinq critères déterminants :

Outils	Intégration	Prise en main	Interactive	Coût d'utilisation	Sécurité
Python	Facile et simple	diffcille	Elevée	Gratuit	moyenne dépend du dev
Power BI	Facile et simple	Simple	Elevée	10 à 20 € par mois par utilisateur	Avancée
Looker-studio	Facile et simple	Très simple	Limitée	Gratuit	Basique
Tableau	Facile et simple	Moyenne	Elevée	Elevé peut atteindre 70€/mois/ utilisateur	Avancée
Excel	Difficile	Très simple	Limitée	Gratuit	Avancée

Tableau 13 : Comparaison des outils de visualisation des données

Choix de l'outil

L'outil Power BI a été retenu pour la visualisation graphique de nos de données, en raison de ses avantages sur les cinq critères. Ce dernier permet aux personnes non technique d'intéragir facilement à grâce à son interface intuitive.

Sélection des modèles de représentation adaptés

Les modèles de représentation de nos données ont été choisis en fonction :

- Des axes d'analyse (temps, source énergétique, équilibrage, performance).
- Des métriques définies en C2.1.2.
- Simplicité de compréhension et d'interprétation.

Objectif	Modèle choisi	Justification
Indicateur de performation énergétique	Carte	Lisibilité et lecture et interprétation simple
Suivi temporel de la prod et conso	Graphique en courbes	Lisibilité des tendances, détection visuelle des anomalies
Analyse des parts de chaque source énergétique	Graphique en anneau	Comparaison rapide des contributions à la production totale
Surveillance du taux de couverture	Indicateur KPI + jauge	Indicateur instantané du niveau de couverture
Corrélations température et production	Nuage de points avec régression	Identification visuelle de la relation et le niveau d'explication
Détection des anomalies mensuelles	Histogramme	Visualisation intuitive des périodes critiques de prod et conso

Tableau 14 : Modèles de représentation

Ces modèles de représentation de données permettent de passer d'une vision et de connaissance théorique à une analyse approfondie (identification des périodes critiques, des tendances énergétiques et des corrélations), tout en garantissant un accès simple et rapide aux informations stratégiques.

Conception et Charte Graphique dans Power BI

Avant de concevoir les différentes pages répondant aux attentes des utilisateurs finaux et d'associer à chaque objectif un visuel interactif, il est essentiel de définir un design clair, intuitif, sobre et moderne.

Design de charte graphique

- **Thème et couleurs :** Un thème sombre a été choisi pour l'arrière-plan afin d'offrir un rendu professionnel et d'améliorer le confort visuel, notamment pour les personnes souffrant de déficience visuelle. Le vert turquoise est utilisé pour le solaire, le bleu sarcelle pour la biomasse, et le vert menthe pastel pour l'éolien. Les indicateurs de niveau adoptent un code couleur classique : vert pour un état satisfaisant et rouge pour un état dégradé.
- **La typographie :** La police Segoe UI, standard dans Power BI, a été conservée pour garantir une lisibilité optimale à l'écran.
- **Mise en page :** Les indicateurs clés de performance sont positionnés en haut pour faciliter la lecture rapide. Les graphiques sont organisés par feuilles thématiques (déficit, production, répartition) afin de simplifier l'analyse. Voir l'exemple la figure 7

Le tableau de bord principal, conçu pour répondre aux besoins des opérateurs et responsables, offre une vue synthétique permettant d'identifier rapidement tendances énergétique voir figure en dessous.

Il se compose de plusieurs sections :

- KPIs : En haut, les indicateurs essentiels (consommation moyenne, production moyenne, taux de couverture, déficit énergétique, production par source) sont affichés avec alertes visuelles sur les seuils critiques.
- Analyse du déficit et de la couverture : Deux histogrammes centraux suivent l'évolution journalière du déficit énergétique et du taux de couverture, répondant au besoin de surveillance quotidienne du réseau.
- Évolution Production vs. Consommation : Un graphique en courbes superposées montre la dynamique entre production (vert) et consommation (bleu), facilitant la détection des pics.
- Répartition des sources : Un diagramme en anneau synthétise la contribution de chaque source d'énergie sur la période.

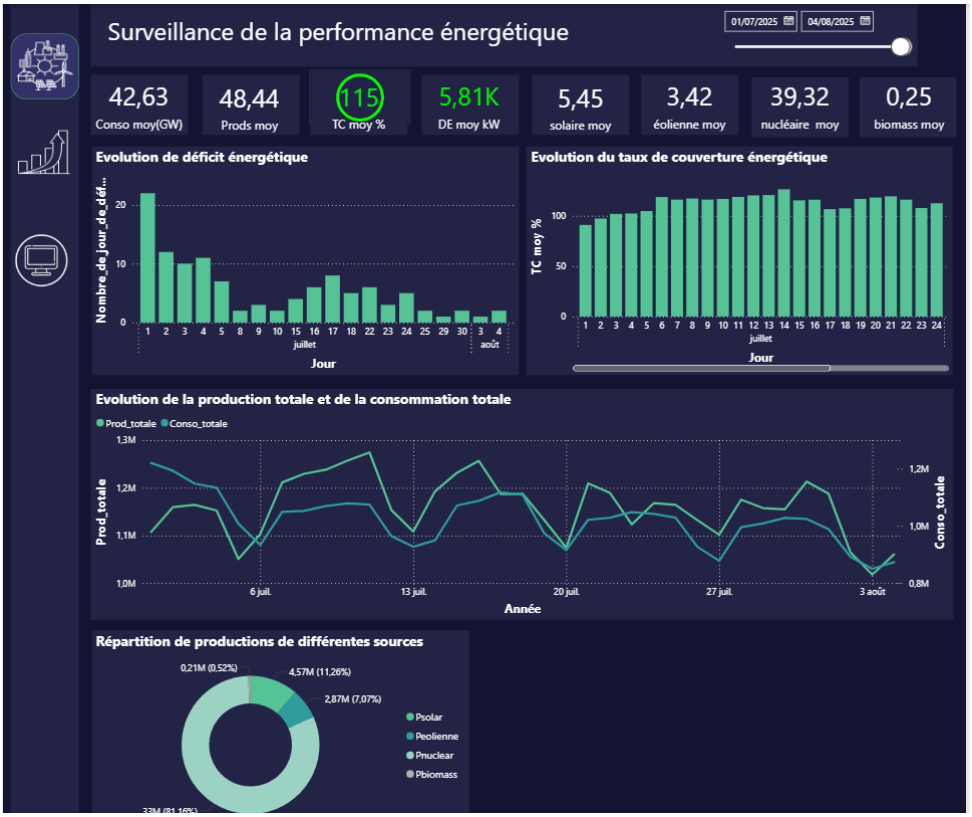

Figure 7 : Page 1 Surveillance de la perfornance

Retours Utilisateurs

Lors d'ateliers avec deux opérateurs et un ingénieur système, la clarté, la simplicité et la réactivité des filtres ont été saluées. La vue Production vs. Consommation a été particulièrement appréciée pour anticiper les déséquilibres.

Les améliorations demandées incluent :

- Un zoom horaire sur les pics de déficit.
- Un filtre par type d'anomalie détectée.
- Des infobulles enrichies avec des données contextuelles (ex. température moyenne).

Ces retours seront intégrés à la prochaine version.

Tests d'Accessibilité

Pour garantir l'usage par tous :

- Le thème sombre respecte les normes WCAG grâce à un contraste optimal.
- La navigation clavier est entièrement fonctionnelle.
- Des textes alternatifs sont ajoutés aux visuels pour les lecteurs d'écran, facilitant l'accès aux personnes malvoyantes.

Grâce à une conception centrée sur l'utilisateur, des choix graphiques pertinents et une validation par les équipes métier, ce tableau de bord Power BI s'impose comme un véritable outil de pilotage, convertissant les données brutes en un levier stratégique de décision pour energIA.

III.2. Recommandations techniques (C2.2.2)

L'analyse statistique approfondie des données énergétiques d'energIA révèle plusieurs constats critiques qui nécessitent une attention particulière et immédiate de la part des décideurs. La forte saisonnalité observée dans le déficit énergétique, avec des pics en hivernaux récurrents, combinée à une concentration significative des anomalies de consommation durant cette même période, expose l'entreprise à des risques opérationnels majeurs. Ces éléments, couplés aux corrélations établies entre température et consommation (R^2 = 0.703), démontrent l'urgence d'adapter les stratégies de pilotage énergétique aux variations de température. La stationnarité confirmée de toutes les séries temporelles constitue néanmoins un atout majeur pour la mise en place de modèles prédictifs robustes, permettant d'anticiper les déséquilibres plutôt que de les subir.

Recommandations opérationnelles

Gestion préventive des périodes critiques

La concentration des anomalies en automne et hiver exige la mise en place d'un plan de surveillance renforcée d'octobre à mars. Il est recommandé d'implémenter des seuils d'alerte dynamiques, ajustés selon la température prévue, permettant d'anticiper les pics de consommation 24 à 48 heures à l'avance. Cette approche proactive réduirait les risques de black-out similaires à ceux observés en Espagne et d'acheter l'énergie à prix élevé.

Optimisation du mix énergétique

L'analyse de la répartition des sources révèle une forte dépendance au nucléaire (corrélation de 0.89 avec la production totale). Pour améliorer la résilience, il est préconisé d'accroître la part des énergies renouvelables durant les périodes de forte production solaire et éolienne, notamment en été, afin de réduire la pression sur les sources conventionnelles durant les pics hivernaux.

Système d'alerte multicritères

La corrélation négative significative entre température consommation et production justifie l'implémentation d'un système d'alerte basé sur des seuils combinant température et taux de couverture. Un taux de couverture inférieur à un seuil, avec une température inférieure à 5°C doit déclencher automatiquement une procédure d'urgence.

Recommandations stratégiques et d'amélioration continue

Développement d'un modèle prévision

Les corrélations et causalités identifiées offrent une base solide pour anticiper les déséquilibres :

- Déployer un modèle de prévision du déficit énergétique basé sur des séries temporelles (SARIMA, Prophet ou LSTM) intégrant production, consommation et données météos.
- Suivre la précision des prévisions via des métriques comme le MAPE ou le RMSE, affichées directement sur le tableau de bord.

Cette capacité prédictive permettrait d'atteindre l'objectif de réduction du taux d'erreur de décision de 20% à moins de 5%, en anticipant les déséquilibres plutôt qu'en réagissant a posteriori.

Enrichissement des données exogènes

Pour améliorer le taux d'explicabilité des résultats au-delà des corrélations actuelles avec la température, il est recommandé d'intégrer d'autres variables météorologiques (vitesse du vent, l'ensoleillement, humidité) et des données calendaires (jours fériés, événements particuliers). Cette approche permettrait d'expliquer une part plus importante de la variabilité observée et d'affiner les modèles de prévision.

Plan d'implémentation et mesure d'impact

1. Phase 1 : Déploiement immédiat (0-3 mois)

Mise en production du tableau de bord Power BI avec formation des utilisateurs finaux. Implémentation des alertes de base sur les seuils critiques identifiés. Objectif : atteindre 80% d'adoption par les équipes techniques dans les trois premiers mois.

2. Phase 2 : Amélioration continue (3-6 mois)

Développement du modèle prédictif et intégration des données météorologiques enrichies. Test des algorithmes de détection d'anomalies en temps réel (Isolation Forest, One-Class SVM) pour améliorer la réactivité face aux incidents.

3. Phase 3 : Optimisation avancée (6-12 mois)

Automatisation complète des rapports d'analyse (objectif 90%) et mise en place d'un système de recommandations automatisées.

Mesure du retour sur investissement (ROI)

L'implémentation de ces recommandations devrait générer des gains mesurables :

- Réduction des coûts liés aux déséquilibres énergétiques estimée à 15-20% grâce à l'anticipation.
- Diminution du temps de réaction aux incidents de 2 heures à 15 minutes maximum.
- Amélioration de la disponibilité du réseau avec un objectif de 99.5% de temps de fonctionnement.

Ces recommandations, fondées sur une analyse rigoureuse des données historiques et des besoins exprimés par les utilisateurs, constituent un plan d'action concret pour transformer energIA en une entreprise pilotée par la donnée, capable d'anticiper et de maîtriser les défis énergétiques actuels.

IV. Accompagnement à l'usage des données

IV.1. Identifiaction public visé (C2.3.1)

L'adoption réussie d'un système d'analyse de données nécessite une approche différenciée selon les profils utilisateurs. L'analyse des entretiens exploratoires menés auprès des sept parties prenantes d'energIA a permis d'identifier quatre segments d'utilisateurs distincts, chacun ayant des besoins spécifiques en termes de formation et d'accompagnement. Cette segmentation constitue la base de notre stratégie de déploiement et de formation.

Utilisateurs finaux

Les utilisateurs finaux d'energIA présentent une grande diversité de compétences techniques et métiers, nécessitant un accompagnement adapté à chacun :

Profil utilisateur	Rôle dans le système	Objectifs de formation
Opérateurs	Surveillance des productions et consommations, identification des déficits	Maîtriser la lecture des indicateurs, utilisation des filtres et alertes
Techniciens et Ingénieurs systèmes	Analyse post-incident, planification de maintenance	Navigation avancée dans les tableaux de bord, extraction et export des données
Data scientist et analyste	Modélisation, détection d'anomalies, prévision	Accès aux données sources, intégration dans des notebooks Python
Responsables métiers	Suivi KPI, pilotage stratégique	Lecture synthétique des KPI, interprétation et prise de décision

Tableau 15 : Segmentation des utilisateurs finaux

Cette répartition montre des réels besoins d'accompagnement hétérogènes. Les opérateurs nécessitent une formation axée sur l'efficacité opérationnelle et la rapidité d'interprétation des alertes. Les ingénieurs requièrent une montée en compétences sur les fonctionnalités

analytiques avancées du tableau de bord. Les responsables métier ont besoin d'être accompagnés sur l'interprétation des indicateurs stratégiques et leur traduction en décisions business.

Analyse des besoins de montée en compétences

L'audit des compétences réalisé lors des réunions a montré les niveaux techniques des utilisateurs finaux de l'outil BI :

- Méconnaissance des outils Power BI : 90% des utilisateurs n'ont jamais exploré Power BI.
- Difficultés d'interprétation statistique : Les concepts de corrélation et de tests d'hypothèses sont peu maîtrisés.
- Manque de culture de données : Absence de réflexes analytiques face aux anomalies.

Détails de la formation et support

Pour créer une formation et un support sur mesure, nous avons collécté les besoins exprimés par chaque profils.

Formation débutant : Responsables

Nous avons prévu 2 heures de formation pour les responsables et les décideurs pour qu'ils puissent comprendre, lire et interpréter les indicateurs clés de performances. Ce qui les aideras à prendre des décisions stratégiques pour l'entreprise.

- Vue d'ensemble du tableau de bord et navigation intuitive.
- Interprétation des KPIs critiques (taux de couverture, déficit énergétique).
- Export et partage des rapports automatisés.

Formation niveau 2 : Opérateurs

Pour les opérateurs de réseau, un programme de 4 heures, réparti en deux ateliers de 2 heures, alternant théorie et mise en pratique sur poste est conçu. Cette formation donc vise à leur donner une maîtrise complète de l'interface Power BI et à leur apprendre à exploiter efficacement les données opérationnelles.

- Utilisation avancée des filtres temporels et par source d'énergie.
- Interprétation des corrélations et détection des anomalies.
- Procédures d'escalade en cas d'alerte critique.
- Personnalisation des vues en fonction des besoins terrain.

Formation niveau 3 : Ingénieurs système

Pour les ingénieurs systèmes, nous avons mis en place un atelier technique approfondi de 6 heures, permettant de comprendre en détail l'architecture du système d'analyse et les modèles statistiques qui le sous-tendent. L'objectif est de les rendre autonomes dans l'optimisation des analyses et l'évolution des outils.

- Architecture technique et flux de données.
- Compréhension et ajustement des modèles statistiques.
- Utilisation des fonctionnalités analytiques avancées.
- Modification des requêtes SQL et des calculs de métriques.
- Réalisation et interprétation de tests d'hypothèse.

IV.2. Documentation technique (C2.3.2)

La documentation technique est un élément indispensable d'un projet informatique, car elle assure la traçabilité, la reproductibilité et la transmission des connaissances. Ainisi, nous avons élaboré une documentation technique simple compréhensible et facilement reproductibilité par d'autres analystes de données. Cette documentation s'adresse à différents publics techniques et vise à garantir l'autonomie des utilisateurs dans l'exploitation, la maintenance et l'évolution de la solution analytique mise en place.

Architecture technique du système

Notre système d'analyse données repose sur une architecture cloud native hébergée sur Google Cloud Platform (GCP), garantissant scalabilité et fiabilité :

- Sources de données et fréquence d'actualisation : voir le tableau 5.
- Pipeline ETL : Orchestration via Apache Airflow pour l'automatisation des flux de données.
- Stockage des données : PostgreSQL et BigQuery pour l'entreposage des données historiques.

Modèle de données

La structure de données s'organise autour de deux vues principales créées dans BigQuery :

- Vue agregation_et_jointure : Vue de consolidation technique
- Vue taux_de_couverture_energetique : Vue métier enrichie

Calcul automatisé des métriques clés : production totale, taux de couverture, déficit énergétique.

Documentation d'utilisation

Nous avons créé trois rapports dans Power BI pour couvrir l'ensemble des objectifs identifiés, à savoir :

- Page de surveillance de performance énergétique : cette page (voir figure 7) offre une vue globale de l'évolution du déficit énergétique, du taux de couverture et de différents indicateurs clés de performance.
- Page d'analyse et tendance : elle permet d'examiner l'évolution des anomalies sur la production totale et la consommation, ainsi que les tendances énergétiques des différentes sources de production, en incluant la corrélation avec la température.
- Page d'interprétation :cette page explique les KPI à travers la variable température, en utilisant des nuages de points et des droites de régression.

Il est possible de naviguer à travers les pages de deux manière : la barre laterale ou les onglets situés en bas du rapport, où chaque page est nommée. .

Utilisation des fonctionnalités principales

- Pour les Opérateurs :
  - Lecture des alters : Indicateurs visuels rouge/vert sur les KPIs critiques.
  - Filtrage temporel : Date du début et fin (jour, mois, année).
  - Export des rapports : Bouton "Exporter"(format PDF ou Excel).

- Pour les Ingénieurs :
  - Analyse des corrélations : Clic sur les treemap.
  - Zoom sur anomalies : Clic sur l'histogramme empilé où il y a des pics détectés pour l'analyse détaillée.
- Pour les Responsables :
  - Vue synthétique : KPIs en haut de page actualisés automatiquement.
  - Rapports automatisés : Consultation via l'onglet "Rapports mensuels".

Analyse hebdomadaire - Ingénieurs

- Exporter les données de production par source énergétique
- Analyser les corrélations température/consommation
- Identifier les patterns d'anomalies saisonnières
- Préparer le rapport de synthèse hebdomadaire

Pilotage mensuel - Responsables

- Consulter le tableau de bord synthétique mensuel.
- Analyser l'évolution des KPIs par rapport au mois précédent.
- Valider les recommandations techniques proposées.

Guide d'utilisation du système

Accès aux données sources

Les utilisateurs techniques peuvent accéder aux données de trois façons :

- BigQuery Console : Requêtage SQL direct pour analyses avancées.
- Notebooks Python : Intégration dans l'environnement BigQuery pour analyses statistiques.
- Power BI : Interface graphique pour consultation et reporting.

Métriques et indicateurs disponibles

Métrique	Calcul	Interprétation
Production totale	BIOMASS + NUCLEAR + SOLAR + WIND_ONSHORE	Capacité de production instantanée
Taux de couverture	(Production totale / Consommation) × 100	Pourcentage de couverture de la demande
Déficit énergétique	Production totale - Consommation	Équilibre offre/demande (positif = excédent)
Détection d'anomalies	Méthode IQR (seuil 1.5)	Identification des valeurs aberrantes

Tableau 16 : Principales métriques et interprétations

Cette documentation technique garantit la traçabilité des développements réalisés et facilite la transmission des connaissances aux équipes techniques d'energIA, assurant ainsi la pérennité et l'évolution continue du système d'analyse énergétique.

V. Synthèse

Ce projet d'analyse de données énergétiques souligne l'importance d'une compréhension approfondie de la culture de pilotage par la donnée.

Ce rapport s'est structuré en trois volets principaux :

Analyse et modélisation des données (C2.1.1 à C2.1.4)

- Collecte des besoins métiers et définition d'indicateurs clés (production, consommation, déficit énergétique, taux de couverture).
- Préparation et traitement des données dans BigQuery.
- Réalisation de tests statistiques et de modèles de corrélation/causalité pour valider les hypothèses.

Nos analyses ont révélé une forte saisonnalité du déficit énergétique et des anomalies ainsi qu'un impact déterminant de la température sur la consommation et la production.

Visualisation et recommandations (C2.2.1 et C2.2.2)

- Développement de tableaux de bord dans Power BI, interactifs et accessibles, facilitant l'identification rapide des tendances, anomalies et périodes critiques.
- Elaboration de recommandations techniques (surveillance accrue en hiver, optimisation du mix énergétique) et de perspectives futures (développement de modèles de prévision, intégration de données exogènes autres que la température).

Accompagnement à l'usage des données (C2.3.1 et C2.3.2)

- Mise en place d'un support de formation adapté à chaque profil (opérateurs, ingénieurs, data scientists, responsables) pour une adoption rapide des outils.
- Création d'une documentation technique, garantissant la traçabilité et la pérennité du système analytique.

Au-delà des performances techniques, ce projet constitue une étape clé dans la transformation d'energIA en organisation pilotée par la donnée. Il permet une compréhension approfondie du réseau électrique et de sa gestion, tout en identifiant les périodes critiques, notamment l'hiver et l'automne où les déficits énergétiques et le nombre d'anomalies sont les plus importants.

En conclusion, le travail mené dans ce Bloc 2 illustre comment la combinaison d'analyses rigoureuses, d'outils de visualisation modernes et d'un accompagnement ciblé transforme des données brutes en un véritable levier de performance, de résilience et de décision stratégique.

VI. Annexes

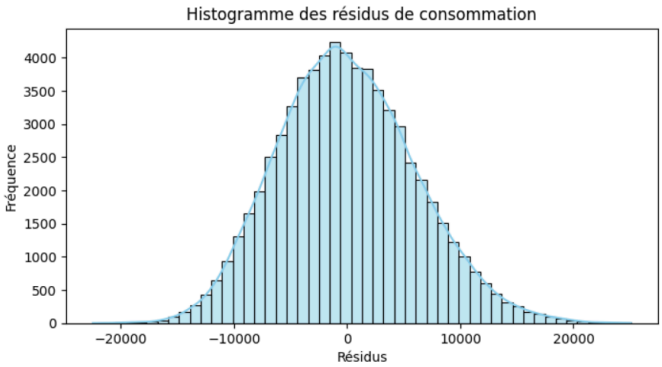

Figure 8 : Distribution des résidus de la consommation totale

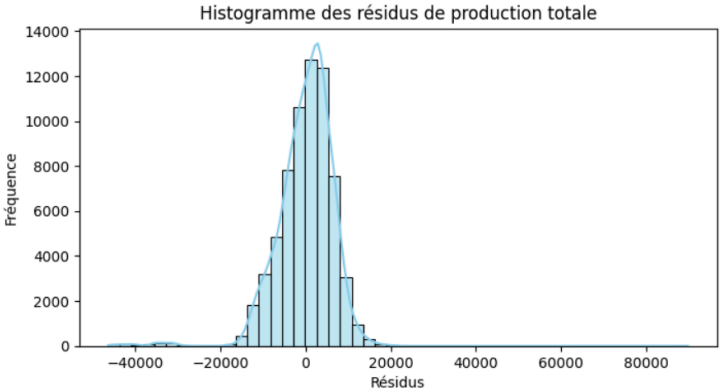

Figure 9 : Distribution des résidus de la production totale

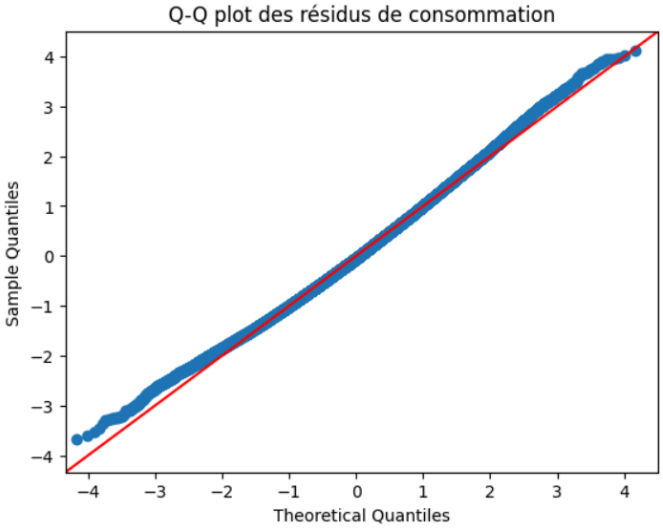

Figure 10 : QQplot des résidus de consommation

Test d'homoscédasticité "données production totale" : LM p-value = 3.33e-251 et F-Stat= 1.56e-253